

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

ОТЧЕТ
по лабораторной работе №2
по дисциплине «Искусственные нейронные сети»
Тема: Бинарная классификация отраженных сигналов радара

Студентка гр. 8382

Кулачкова М.К.

Преподаватель

Жангиров Т.Р.

Санкт-Петербург

2021

Цель работы

Реализовать классификацию между камнями (R) и металлическими цилиндрами (M) на основе данных об отражении сигналов радара от поверхностей.

60 входных значений показывают силу отражаемого сигнала под определенным углом. Входные данные нормализованы и находятся в промежутке от 0 до 1.

Задачи

- Ознакомиться с задачей бинарной классификации
- Загрузить данные
- Создать модель ИНС в tf.Keras
- Настроить параметры обучения
- Обучить и оценить модель
- Изменить модель и провести сравнение. Объяснить результаты

Требования

- Изучить влияние кол-ва нейронов на слое на результат обучения модели
- Изучить влияние кол-ва слоев на результат обучения модели
- Построить графики ошибки и точности в ходе обучения
- Провести сравнение полученных сетей, объяснить результат

Выполнение работы

Загружаются данные об отражении сигналов радара из файла *sonar.csv*. Входные параметры отделяются от выходного. Выходные параметры переводятся в целочисленные значения.

Задается базовая архитектура сети. Модель включает в себя один скрытый слой, содержащий 60 нейронов, и выходной слой из одного нейрона с сигмоидной функцией активации.

```
model.add(Dense(60, input_dim=60,  
kernel_initializer='random_normal', activation='relu'))  
model.add(Dense(1, kernel_initializer='random_normal',  
activation='sigmoid'))
```

Проводится обучение сети. Сеть обучается в течение 100 эпох батчами по 10 образцов. На рис. 1 и 2 представлены графики ошибок и точности на обучающем и валидационном множествах.




Рисунок 1




Рисунок 2

Уменьшим количество нейронов на первом слое в два раза и проведем переобучение сети.

```
model.add(Dense(30, input_dim=60,  
kernel_initializer='random_normal', activation='relu'))  
model.add(Dense(1, kernel_initializer='random_normal',  
activation='sigmoid'))
```

На рис. 3 и 4 представлены графики ошибок и точности на обучающем и валидационном множествах.




Рисунок 3




Рисунок 4

Если сравнить полученные графики с графиками, полученными при использовании большего слоя, можно заметить, что скорость обучения уменьшилась, а итоговая точность модели практически не изменилась. Из этого можно сделать вывод, что в рассматриваемом наборе данных присутствует некоторая избыточность и нет необходимости использовать слой с большим количеством нейронов.

Добавим в исходную архитектуру сети скрытый слой с 15 нейронами и обучим полученную сеть.

```
model.add(Dense(60, input_dim=60,  
kernel_initializer='random_normal', activation='relu'))  
model.add(Dense(15, input_dim=60,  
kernel_initializer='random_normal', activation='relu'))  
model.add(Dense(1, kernel_initializer='random_normal',  
activation='sigmoid'))
```

На рис. 5 и 6 представлены графики ошибок и точности на обучающем и валидационном множествах.




Рисунок 5




Рисунок 6

Как видно на графиках, точность предсказания на валидационном множестве несколько увеличилась. Это связано с тем, что добавление дополнительного слоя позволяет обнаруживать более сложные закономерности и взаимосвязи.

Исследуем также модель, содержащую два скрытых слоя с 30 и 15 нейронами.

```
model.add(Dense(30, input_dim=60,
kernel_initializer='random_normal', activation='relu'))
model.add(Dense(15, input_dim=60,
kernel_initializer='random_normal', activation='relu'))
model.add(Dense(1, kernel_initializer='random_normal',
activation='sigmoid'))
```

На рис. 7 и 8 представлены графики ошибок и точности на обучающем и валидационном множествах. Как видно на графиках, качество обучения ухудшилось по сравнению с моделью, у которой на первом скрытом слое 60 нейронов, но несколько улучшилась по сравнению с моделью, у которой один слой из 30 нейронов.




Рисунок 7




Рисунок 8

Также можно заметить, что, начиная примерно с 65 эпохи точность предсказания на валидационном множестве стала ухудшаться, что свидетельствует о переобучении модели.

Если сравнить все рассмотренные модели, можно прийти к выводу, что модель, имеющая два скрытых слоя с 60 и 15 нейронами, позволяет достигать наилучшей точности.

Выводы

В ходе выполнения работы была создана искусственная нейронная сеть, осуществляющая бинарную классификацию между камнями и металлическими цилиндрами на основе данных об отражении сигналов радара от поверхностей.

Было рассмотрено несколько различных архитектур для исследования влияния количества нейронов на слое и количества слоев в сети на результат обучения модели. Количество нейронов на слое влияет на количество признаков, с которыми работает нейросеть. Было определено, что в данном конкретном случае в модели с большим количеством нейроном нет необходимости, однако она обучается быстрее, что может быть полезным. Дополнительные слои позволяют находить более сложные закономерности в рассматриваемых данных, что повышает точность модели, а также способствуют более быстрому обучению сети. Также обнаружено, что комбинация количества слоев и числа нейронов на слоях имеет значение: несмотря на то, что модель с 30 нейронами на скрытом слое позволяла достигать такой же точности, что и модель с 60 нейронами, когда скрытый слой был только один, при добавлении второго скрытого слоя модель с более широким слоем давала лучшие результаты.