

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра математического обеспечения и применения ЭВМ

ОТЧЕТ
по лабораторной работе №2
по дисциплине «Искусственные нейронные сети»
Тема: Бинарная классификация отраженных сигналов радара

Студент гр. 8383

Преподаватель

Муковский Д. В.

Жангиров Т. Р.

Санкт-Петербург

2021

Цель работы

Реализовать классификацию между камнями (R) и металлическими цилиндрами (M) на основе данных об отражении сигналов радара от поверхностей. 60 входных значений показывают силу отражаемого сигнала под определенным углом. Входные данные нормализованы и находятся в промежутке от 0 до 1.

Задачи

- Ознакомиться с задачей бинарной классификации
- Загрузить данные
- Создать модель ИНС в tf.Keras
- Настроить параметры обучения
- Обучить и оценить модель
- Изменить модель и провести сравнение. Объяснить результаты

Требования

1. Изучить влияние кол-ва нейронов на слое на результат обучения модели.
2. Изучить влияние кол-ва слоев на результат обучения модели
3. Построить графики ошибки и точности в ходе обучения
4. Провести сравнение полученных сетей, объяснить результат

Выполнение работы.

1. Сначала были импортированы все нужные классы и функции.
2. После чего были разделены атрибуты на входные данные(X) и выходные данные(Y). Выходные данные были переведены в целочисленные значения 0 и 1.
3. Далее была создана базовая архитектура сети, состоящая из входного слоя с input_dim 60, скрытым слоем из 60 нейронов с активизирующей

функцией RELU и выходным слоем нейронов с активизирующей функцией sigmoid.

4. Также были настроены три параметра для этапа компиляции: функция потерь – binary crossentropy, оптимизатор – adam и метрика для мониторинга – точность.
5. Далее были инициализированы параметры обучения. Обучение проводится в течение 100 эпох по 10 образцов для валидации отведено 10 % данных.
6. После чего происходила отрисовка графиков потери сети на обучающих данных и точность сети на обучающих данных, а также потери и точность на данных, не участвовавших в обучении.

Тесты

1. Результаты тестирования стартовой ИНС представлены на рис. 1, 2.




Рисунок 1 – График потери ИНС



Рисунок 2 – График точности ИНС

В представленном наборе данных присутствует некоторая избыточность, т.к. с разных углов описывается один и тот же сигнал. Вероятно, что некоторые углы отражения сигнала имеют большую значимость, чем другие. Изменение количества нейронов во входном слое напрямую влияет на количество признаков, с которыми будет работать нейронная сеть.

Уменьшим размер входного слоя в два раза, новые графики представлены на рис. 3, 4.




Рисунок 3 – График потери ИНС




Рисунок 4 – График точности ИНС

Ошибка увеличилась, а точность немного уменьшилась. Значит в данном случае нашей ИНС недостаточно признаков во входных данных.

Теперь добавим промежуточный слой с 15 нейронами. Нейронная сеть с несколькими слоями позволяет находить закономерности не только во входных данных, но и в их комбинации. Также дополнительные слои позволяют ввести нелинейность в сеть, что позволяет получать более высокую точность.

Результаты новой ИНС представлены на рис. 5 и 6.




Рисунок 5 – График потери ИНС




Рисунок 6 – График точности ИНС

Точность значительно выросла, а ошибка уменьшилась, что показывает превосходство данной архитектуры ИНС над предыдущими.

Вернем количество нейронов во входном слое равным 60. Результаты представлены на рис. 7 и 8.




Рисунок 7 – График потери ИНС




Рисунок 8 – График точности ИНС

На графиках видно, что сеть начинает переобучаться после 40 поколений, что доказывает избыточность во входных данных.

Лучшая модель представлена в приложении А.

Выводы.

В ходе выполнения работы была создана ИНС, осуществляющая бинарную классификацию между камнями и металлическими цилиндрами на основе данных об отражении сигналов радара от поверхностей. Было рассмотрено несколько различных архитектур для исследования влияния количества нейронов на слое в сети и количества слоев в сети на результат обучения модели.

ПРИЛОЖЕНИЕ А

```
import pandas
from tensorflow.keras.layers import Dense
from tensorflow.keras.models import Sequential
from sklearn.preprocessing import LabelEncoder
import matplotlib.pyplot as plt

dataframe = pandas.read_csv("sonar.csv", header=None)
dataset = dataframe.values
X = dataset[:, 0:30].astype(float)
Y = dataset[:, 60]

encoder = LabelEncoder()
encoder.fit(Y)
encoded_Y = encoder.transform(Y)

model = Sequential()
model.add(Dense(60, input_dim=30, kernel_initializer='normal', activation='relu'))
model.add(Dense(15, kernel_initializer='normal', activation='relu'))
model.add(Dense(1, kernel_initializer='normal', activation='sigmoid'))

model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])

H = model.fit(X, encoded_Y, epochs=100, batch_size=10, validation_split=0.1)

loss = H.history['loss']
val_loss = H.history['val_loss']
acc = H.history['accuracy']
val_acc = H.history['val_accuracy']
epochs = range(1, len(loss) + 1)

plt.plot(epochs, loss, 'r', label='Training loss')
plt.plot(epochs, val_loss, 'b', label='Validation loss')
plt.title('Training and validation loss')
plt.xlabel('Epochs')
plt.ylabel('Loss')
plt.legend()
plt.show()
```

```
plt.clf()
plt.plot(epochs, acc, 'r', label='Training acc')
plt.plot(epochs, val_acc, 'b', label='Validation acc')
plt.title('Training and validation accuracy')
plt.xlabel('Epochs')
plt.ylabel('Accuracy')
plt.legend()
plt.show()
```