МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)

Кафедра математического обеспечения и применения ЭВМ

ОТЧЕТ

по лабораторной работе №7
по дисциплине «Искусственные нейронные сети»
Тема: Классификация обзоров фильмов

Студент гр. 8383	 Шишкин И.В.
Преподаватель	Жангиров Т.Р.

Санкт-Петербург

Цель работы.

Классификация последовательностей — это проблема прогнозирующего моделирования, когда у вас есть некоторая последовательность входных данных в пространстве или времени, и задача состоит в том, чтобы предсказать категорию для последовательности.

Проблема усложняется тем, что последовательности могут различаться по длине, состоять из очень большого словарного запаса входных символов и могут потребовать от модели изучения долгосрочного контекста или зависимостей между символами во входной последовательности.

В данной лабораторной работе также будет использоваться датасет IMDb, однако обучение будет проводиться с помощью рекуррентной нейронной сети.

Задачи.

- Ознакомиться с рекуррентными нейронными сетями
- Изучить способы классификации текста
- Ознакомиться с ансамблированием сетей
- Построить ансамбль сетей, который позволит получать точность не менее 97%

Выполнение работы.

Построена нейронная сеть, представленная в листинге 1.

Листинг 1 – Модель №1

Результат работы модели №1 с 3 эпохами представлен в листинге 2.

Листинг 2 – Результат модели №1

Точность у модели №1 – 92% на обучающих и 88% на тестовых.

Для модели №2 добавим одномерный слой CNN и максимальный пул после слоя Embedding (листинг 3).

Листинг 3 – Модель №2

Результат работы модели №2 с 3 эпохами представлен в листинге 4.

Листинг 4 – Результат модели №2

Точность у модели №2 – 94% на обучающих и 89% на тестовых.

Добавим слои Dropout для модели №3 (листинг 5).

Листинг 5 – Модель №3

Результат работы модели №3 с 3 эпохами представлен в листинге 6.

Листинг 6 – Результат модели №3

Точность у модели №3 – 95% на обучающих и 89 % на тестовых.

Так как модель №3 показала лучшие результаты, применим для нее ансамблирование. Создадим 5 разных моделей №3 с разными данными (листинг 7).

Листинг 7 – Ансамблирование

```
models = []
scores = []
m = 4
```

```
for i in range(m):
   x train = train x[int(len(train_x) / m) * i: int(len(train_x) / m)
* (i + 1)]
    y_train = train_y[int(len(train_y) / m) * i: int(len(train_y) / m)
* (i + 1)]
   models.append(Sequential())
   models[i].add(Embedding(max words, embedding vector length,
input length=max review length))
    models[i].add(Conv1D(filters=32, kernel size=3, padding='same',
activation='relu'))
   models[i].add(MaxPooling1D(pool size=2))
   models[i].add(Dropout(0.2))
   models[i].add(LSTM(100))
   models[i].add(Dropout(0.2))
   models[i].add(Dense(1, activation='sigmoid'))
   models[i].compile(loss='binary crossentropy', optimizer='adam',
metrics=['accuracy'])
   models[i].fit(x_train, y_train, validation_data=(x_train, y_train),
epochs=3, batch size=64)
   print(models[i].evaluate(x train, y train, verbose=0))
    scores.append(models[i].evaluate(x train, y train, verbose=0)[1])
print("Mean accuracy: %.2f%%" % (np.mean(scores) * 100))
```

Программа выдала следующий результат:

Mean accuracy: 97.22%

Были написаны функции для пользовательского текста.

Вывод программы для текста "it is not good film. i am upset":

```
Mean predictions 53.35% Good
```

Вывод программы для текста "It's not so bad, but I cannot advise him to others":

```
Mean predictions 19.73% Bad
```

Вывод программы для текста "It's bad film":

Mean predictions 27.98%

Bad

Вывод программы для текста "it's very good film!":

Mean predictions 79.96%

Good

Вывод программы для текста "it is not horrible film, the acting is not bad":

Mean predictions 6.02%

Bad

Вывод программы для текста "it is good film. i am not upset":

Mean predictions 59.46%

Good

Выводы.

Был найден оптимальный набор ИНС для классификации текста. Проведено ансамблирование моделей. Написана функция, которая позволяет загружать текст и получать результат ансамбля сетей. Проведено тестирование сетей на своих текстах.