

**МИНОБРНАУКИ РОССИИ**  
**САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ**  
**ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ**  
**«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)**  
**Кафедра МО ЭВМ**

**ОТЧЕТ**  
**по лабораторной работе №2**  
**по дисциплине «Искусственные нейронные сети»**  
**Тема: Бинарная классификация отраженных сигналов радара**

Студентка гр. 8383

\_\_\_\_\_

Гречко В.Д.

Преподаватель

\_\_\_\_\_

Жангиров Т.Р.

Санкт-Петербург

2021

### **Цель работы.**

Реализовать классификацию между камнями (R) и металлическими цилиндрами (M) на основе данных об отражении сигналов радара от поверхностей.

60 входных значений показывают силу отражаемого сигнала под определенным углом. Входные данные нормализованы и находятся в промежутке от 0 до 1.

### **Задачи.**

- Ознакомиться с задачей бинарной классификации
- Загрузить данные
- Создать модель ИНС в tf.Keras
- Настроить параметры обучения
- Обучить и оценить модель
- Изменить модель и провести сравнение. Объяснить результаты

### **Выполнение работы.**

#### **1. Написание первой модели ИНС.**

Данные были получены из файла *sonar.csv*. Далее была выполнена загрузка данных и переход от строк (“R” и “M”) к целочисленным значениям 0 и 1 соответственно. После этого была создана модель со следующими параметрами: один скрытый слой, содержащий 60 нейронов, и выходной слой из одного нейрона с сигмоидной функцией активации. Обучение сети проводится в течении 100 эпох батчами по 10 образцов.

Графики потерь и точности представлены на рисунках 1 и 2.




Рисунок 1 – график точности




Рисунок 2 – график потерь

## 2. Изучение различных архитектур ИНС (Разное кол-во слоев, разное кол-во нейронов на слоях)

В представленном наборе данных присутствует некоторая избыточность, т.к. с разных углов описывается один и тот же сигнал. Вероятно, что некоторые углы отражения сигнала имеют большую значимость, чем другие. Изменение количества нейронов во входном слое напрямую влияет на количество признаков, с которыми будет работать нейронная сеть.

Поэтому рассмотрим вариант с уменьшением размера входного слоя в два раза.

```
model.add(Dense(30, input_dim=60, kernel_initializer='normal', activation='relu'))
```

Графики потерь и точности представлены на рисунках 3 и 4.




Рисунок 3 – график точности

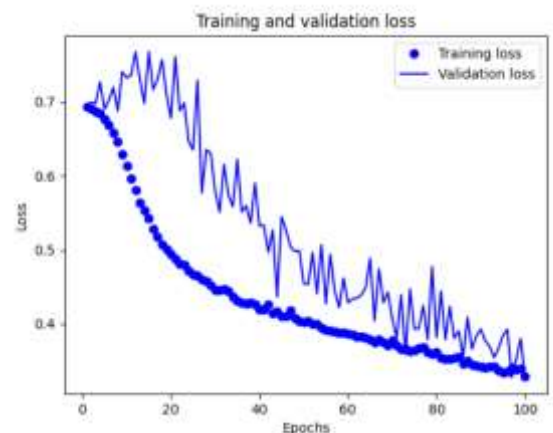


Рисунок 4 – график потерь

Вывод: результаты работы ИНС доказали избыточность в наборе данных. Как видно из графика точности – скорость обучения улучшилась, а доказанная ранее избыточность позволила уменьшить количество нейронов на входном слое.

Нейронная сеть с несколькими слоями позволяет находить закономерности не только во входных данных, но и в их комбинации. Также, дополнительные слои позволяют ввести нелинейность в сеть, что позволяет получать более высокую точность.

Рассмотрим вариант с добавлением промежуточного слоя Dense в архитектуру сети с 15 нейронами.

```
model.add(Dense(30, input_dim=60, kernel_initializer='normal', activation='relu'))
model.add(Dense(15, input_dim=60, kernel_initializer='normal', activation='relu'))
model.add(Dense(1, kernel_initializer='normal', activation='sigmoid'))
```

Графики потерь и точности представлены на рисунках 5 и 6.




Рисунок 5 – график точности




Рисунок 6 – график потерь

Вывод: добавление промежуточного слоя немного улучшило результаты работы ИНС, так как это внесло нелинейность в сеть.

Рассмотрим другой вариант с добавлением промежуточного слоя Dense в архитектуру сети с 15 нейронами.

```
model.add(Dense(60, input_dim=60, kernel_initializer='normal', activation='relu'))
model.add(Dense(15, input_dim=60, kernel_initializer='normal', activation='relu'))
model.add(Dense(1, kernel_initializer='normal', activation='sigmoid'))
```

Графики потерь и точности представлены на рисунках 7 и 8.




Рисунок 7 – график точности




Рисунок 8 – график потерь

Вывод: увеличение нейронов на входном слое улучшило точность ИНС.

Рассмотри ещё один вариант с добавлением ещё одного промежуточного слоя с 15 нейронами.

```
model.add(Dense(60, input_dim=60, kernel_initializer='normal', activation='relu'))
model.add(Dense(15, input_dim=60, kernel_initializer='normal', activation='relu'))
model.add(Dense(15, input_dim=60, kernel_initializer='normal', activation='relu'))
model.add(Dense(1, kernel_initializer='normal', activation='sigmoid'))
```

Графики потерь и точности представлены на рисунках 9 и 10.




Рисунок 9 – график точности




Рисунок 10 – график потерь

Вывод: добавление еще одного слоя нейронов не привело к улучшению показателей точности и ошибок.

Исходя из всех исследований можно определить наилучшую модель:

```
model.add(Dense(60, input_dim=60, kernel_initializer='normal', activation='relu'))
model.add(Dense(15, input_dim=60, kernel_initializer='normal', activation='relu'))
model.add(Dense(1, kernel_initializer='normal', activation='sigmoid'))
```

## **Выводы.**

В ходе выполнения работы была создана искусственная нейронная сеть, осуществляющая бинарную классификацию между камнями и металлическими цилиндрами на основе данных об отражении сигналов радара от поверхностей. Было рассмотрено несколько различных архитектур для исследования влияния количества нейронов на слое и количества слоев в сети на результат обучения модели.