МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА) Кафедра МОЭВМ

ОТЧЕТ

по лабораторной работе №6 по дисциплине «Искусственные нейронные сети»

Тема: Прогноз успеха фильмов по обзорам

Студент гр. 8383	 Сосновский Д. Н
Преподаватель	Жангиров Т. Р.

Санкт-Петербург

Цель работы.

Прогноз успеха фильмов по обзорам (Predict Sentiment From Movie Reviews).

Задачи.

- 1. Ознакомиться с задачей классификации
- 2. Изучить способы представления текста для передачи в ИНС
- 3. Достигнуть точности прогноза не менее 95%

Требования

- 1. Построить и обучить нейронную сеть для обработки текста
- 2. Исследовать результаты при различном размере вектора представления текста
- 3. Написать функцию, которая позволяет ввести пользовательский текст

Ход работы.

Согласно методическим указаниям была построена и обучена нейронная сеть. Исходный код программы приведён в приложении А. Архитектура модели имеет вид, изображенный на рисунке ниже.


```
# Input - Layer
model = Sequential()
model.add(layers.Dense(50, activation="relu", input_shape=(10000,)))
# Hidden - Layers

model.add(layers.Dropout(0.3, noise_shape=None, seed=None))
model.add(layers.Dense(50, activation="relu"))
model.add(layers.Dropout(0.2, noise_shape=None, seed=None))
model.add(layers.Dense(50, activation="relu"))
# Output- Layer
model.add(layers.Dense(1, activation="sigmoid"))
```

Данная архитектура нейросети достигает точности 90% на исходных данных. Результат представлен на рисунке ниже.

```
Epoch 1/2
80/80 [==============] - 3s 37ms/step - loss: 0.5218 - accuracy: 0.7310 - val_loss: 0.2575 - val_accuracy: 0.8971
Epoch 2/2
80/80 [==============] - 1s 18ms/step - loss: 0.2140 - accuracy: 0.9186 - val_loss: 0.2656 - val_accuracy: 0.8941
0.896275000333786
```

Графики потерь и точности на тренировочных и валидационных наборах данных представлены на рисунке ниже.



Исследование результатов при различном размере вектора представления текста.

Проведем исследование изменения точности сети при уменьшении размера вектора с 10000 до 3000 и 1000. Результаты представлены на рисунках ниже.

Рисунок 1 – точность при размере вектора 3000

Рисунок 1 – точность при размере вектора 1000

Таким образом, при уменьшении размера вектора точность также уменьшается, исходя из сравнения запусков с запуском размера вектора 10000.

Реализация функции ввода текста.

Была реализована функция textInput() для того, чтобы считывать ввод текста пользователем с консоли. Исходный код функции приведён в листинге ниже.

Преобразуем исходный текст в массив слов, и ищем для каждого слова его рейтинг в словаре imdb. Далее передаём векторизированный список слов нейронной сети и выводим результат. Пример работы функции представлен на рисунках ниже.

```
Epoch 1/2
80/80 [=============] - 3s 37ms/step - loss: 0.5302 - accuracy: 0.7337 - val_loss: 0.2595 - val_accuracy: 0.8999
Epoch 2/2
80/80 [==============] - 2s 19ms/step - loss: 0.2119 - accuracy: 0.9213 - val_loss: 0.2623 - val_accuracy: 0.8936
0.8693499863147736
This novie is really nice! I recommend all my friends to watch it.
[[20, 9, 66, 386, 32, 61, 369, 8, 106]]
[[0.6678782]]

Epoch 1/2
80/80 [==============] - 3s 36ms/step - loss: 0.5145 - accuracy: 0.7493 - val_loss: 0.2579 - val_accuracy: 0.8958
Epoch 2/2
80/80 [===============] - 2s 19ms/step - loss: 0.2090 - accuracy: 0.9217 - val_loss: 0.2651 - val_accuracy: 0.8940
0.894899994134903
This is the best movie I have ever seen! I would like to watch this movie again!
[[9, 4, 118, 20, 28, 126, 62, 40, 8, 106, 14, 20]]
```

Вывод.

В ходе выполнения лабораторной работы была создана нейронная сеть для прогнозирования успеха фильма по обзору. Была реализована функция для ввода пользовательского текста. Был изучен способ представления текста для передачи в нейронную сеть.

ПРИЛОЖЕНИЕ А

В этом приложении приведён исходный код программы.

```
import matplotlib.pyplot as plt
from matplotlib import gridspec
import numpy as np
from keras.models import Sequential
from keras.datasets import imdb
from tensorflow.python.keras.applications.densenet import layers
(training data, training targets), (testing data, testing targets) =
imdb.load data(num words=10000)
data = np.concatenate((training_data, testing data), axis=0)
targets = np.concatenate((training targets, testing targets), axis=0)
print("Categories:", np.unique(targets))
print("Number of unique words:", len(np.unique(np.hstack(data))))
length = [len(i) for i in data]
print("Average Review length:", np.mean(length))
print("Standard Deviation:", round(np.std(length)))
print("Label:", targets[0])
print(data[0])
index = imdb.get word index()
reverse index = dict([(value, key) for (key, value) in index.items()])
decoded = " ".join([reverse index.get(i - 3, "#") for i in data[0]])
print(decoded)
def vectorize(sequences, dimension=10000):
    results = np.zeros((len(sequences), dimension))
    for i, sequence in enumerate(sequences):
        results[i, sequence] = 1
    return results
data = vectorize(data)
targets = np.array(targets).astype("float16")
test x = data[:10000]
test_y = targets[:10000]
train x = data[10000:]
train y = targets[10000:]
# Input - Layer
model = Sequential()
model.add(layers.Dense(50, activation="relu", input_shape=(10000,)))
# Hidden - Layers
model.add(layers.Dropout(0.3, noise_shape=None, seed=None))
model.add(layers.Dense(50, activation="relu"))
model.add(layers.Dropout(0.2, noise shape=None, seed=None))
```

```
model.add(layers.Dense(50, activation="relu"))
# Output- Layer
model.add(layers.Dense(1, activation="sigmoid"))
model.summary()
model.compile(optimizer="adam", loss="binary crossentropy",
metrics=["accuracy"])
results = model.fit(train x, train y, epochs=2, batch size=500,
validation data=(test x, test y))
print(np.mean(results.history["val accuracy"]))
def draws(H):
    loss = H.history['loss']
    val loss = H.history['val loss']
    acc = H.history['accuracy']
    val acc = H.history['val_accuracy']
    epochs = range(1, len(loss) + 1)
    fig = plt.figure(figsize=(12, 6))
    gs = gridspec.GridSpec(1, 2, width ratios=[3, 3])
    plt.subplot(gs[0])
   plt.plot(epochs, loss, 'r', label='Training loss')
   plt.plot(epochs, val_loss, 'g', label='Validation loss')
    plt.title('Training and validation loss')
    plt.xlabel('Epochs')
    plt.ylabel('Loss')
    plt.legend()
    plt.subplot(gs[1])
    plt.plot(epochs, acc, 'r', label='Training acc')
   plt.plot(epochs, val_acc, 'g', label='Validation acc')
    plt.title('Training and validation accuracy')
    plt.xlabel('Epochs')
    plt.ylabel('Accuracy')
    plt.legend()
    plt.tight layout()
    plt.show()
draws(results)
def textInput():
   words = input().split(' ')
```

```
imdb_dict = imdb.get_word_index()
words_rate = []
tmp = []

words_range = 1000
for word in words:
    if imdb_dict.get(word) in range(1, words_range):
        tmp.append(imdb_dict.get(word) + 3)
words_rate.append(tmp)

print(words_rate)
words_rate = vectorize(words_rate)
result = model.predict(words_rate)
print(result)

if __name__ == '__main__':
textInput()
```